

# Двойственный подход к обучению генеративных состязательных сетей

М.Г.Бочко, Е.А.Жестов, А.Р.Хуснутдинов

*Московский физико-технический институт (национальный исследовательский  
университет)*

*141701, Московская область, г. Долгопрудный, Институтский переулок, д.9.*

---

## Abstract

В данной работе будет проанализирован новый метод тренировки генеративно-состязательных нейронных сетей. В его основе лежит переформулирование исходной минимаксной задачи как задачи нахождения седловой точки лагранжиана выпуклой оптимизации. В двойственной задаче значения функции дискриминатора будут играть роль прямых переменных, а сгенерированное распределение - роль двойственной переменной. Новый взгляд на задачу обучения приводит к модификации правил обновления параметра генератора. Будут проведены эксперименты, мотивирующие исследовать границы применимости предложенного метода.

---

## 1. Введение

Генеративно-состязательная сеть (GAN) представляет собой алгоритм машинного обучения, построенный на комбинации из двух нейронных сетей. Первая нейронная сеть называется *генератором*, а вторая *дискриминатором*. Генератор сэмплирует данные из случайного шума. Дискриминатор же классифицирует данные, т.е старается отличить сгенерированные от подлинных.

Целью генератора является повысить процент ошибок дискриминатора, а целью дискриминатора является, наоборот, улучшение точности распознавания. Такие нейронные сети впервые были предложены в статье [1].

Задача обучения GAN формулируется как следующая минимаксная задача:

$$\min_G \max_D \mathbb{E}_{x \sim p_d(x)} \{\log D(x)\} + \mathbb{E}_{z \sim p_z(z)} \{\log(1 - D(G(z)))\}, \quad (1)$$

12 где  $D(x) : \mathbb{R}^n \rightarrow \{1, 0\}$  - функция дискриминатора, определяющая мет-  
13 ку класса по входному вектору  $x$ ,  $p_d$  — истинное распределение данных,  
14  $G(z) : \mathbb{R}^k \rightarrow \mathbb{R}^n$  — функция генератора для создания данных из про-  
15 странства с некоторым распределением  $p_z(z)$ .

16 Дискриминатор и генератор определяются параметрами  $\theta_d$  и  $\theta_g$  соответ-  
17 ственно. Параметры генератора и дискриминатора обновляются итера-  
18 тивно с помощью градиентного спуска.

19 В работе [2] описана проблема, связанная с обучением, которая состоит  
20 в том, что в какой-то момент генератор начинает предлагать одну и ту  
21 же модель, лучше всего подходящую под дискриминатор. Эта проблема  
22 называется *коллапсом моды*. Для корректной работы GAN необходимо,  
23 чтобы генерировались все классы данных, в противном случае обучение  
24 дискриминатора происходит на несбалансированной выборке.

25 В работе рассматривается замена задачи на эквивалентную: вместо на-  
26 хождения оптимальных параметров сети мы ищем седловую точку лагран-  
27 жиана задачи выпуклой оптимизации. Данная задача специально по-  
28 добрана так, чтобы её решение было эквивалентно решению исходной  
29 минимаксной задачи. Нами ожидается, что это поможет избежать про-  
30 блемы коллапса моды и приведет к улучшению работы сети.

### 31 1.1. Обзор литературы

32 Впервые GAN были предложены в статье [1]. Практическая польза GAN  
33 заключается в возможности создания реалистичных изображений, тек-  
34 стов, музыки [3]. Тем не менее, они обладают рядом недостатков, главны-  
35 ми из них являются сложность обучения и анализ сходимости. Общий  
36 обзор решений этой проблемы дается в статье [2], авторы которой от-  
37 дельно фокусируются на рассмотрении задачи с оптимизационной точки  
38 зрения. В этой работе рассматриваются три типа решений. Первый тип  
39 — это использование непараметрических моделей генератора и дискри-  
40 минатора ([4]). Второй тип — использование так называемой «разверну-  
41 той оптимизации», при которой дискриминатор остается оптимальным

или почти оптимальным в процессе генерации ([5]). Третий тип – рассмотрение оптимизации сетей через прямо-двойственную задачу. Данная работа опирается на статью [6]. Наша задача заключается в проведении модифицированных экспериментов, проверяющих эффективность прямо-двойственного подхода.

## 2. Постановка задачи

Мы предлагаем альтернативный подход к постановке задачи: сформулировать задачу как нахождение седловой точки лагранжиана задачи выпуклой оптимизации. Предположим, что исходные данные и сгенерированные принадлежат конечному множеству  $\{x_1, \dots, x_n\}$  заданного размера  $n$ . Реальные данные имеют конечный размер, поэтому нам интересен именно этот случай. Поставим следующую задачу оптимизации

$$\begin{aligned} \max \sum_{i=1}^n p_d(x_i) \log(D_i) \\ s.t. \log(1 - D_i) \geq \log(1/2), \quad i = \overline{1, n} \\ \mathbf{D} \in \mathcal{D}, \end{aligned}$$

где  $\mathcal{D}$  некоторое выпуклое множество. Прямые переменные в ней:  $\mathbf{D} = (D_1, \dots, D_n)$ , где  $D_i = D(x_i)$ . Пусть  $p_g = (p_g(x_1), \dots, p_g(x_n))$ , где  $p_g(x_i)$  —  $i$ -ая двойственная переменная. Функция Лагранжа в этом случае запишется как

$$L(\mathbf{D}, p_g) = \sum_{i=1}^n p_d(x_i) \log(D_i) + \sum_{i=1}^n p_g(x_i) \log(2(1 - D_i)), \quad (2)$$

где  $\mathbf{D} \in \mathcal{D}$ . В случае  $\mathcal{D} = \{\mathbf{D} : 0 \leq D_i \leq 1, \forall i\}$  поиск седловой точки лагранжиана в точности эквивалентен решению задачи (1). Это свойство позволяет переработать прямо-двойственный субградиентный метод для обновления значений  $D(x)$  и  $p_g(x)$ , так как они будут сходиться к седловой точке.

## 3. Методы

В этом разделе мы представим псевдокод предложенного метода обучения GAN (**Algorithm 1**) и дадим его описание. Обновление параметра

56 дискриминатора в предложенном алгоритме такое же , как и в стандарт-  
 57 ном методе обучения. Отличие от стандартного метода заключается в  
 58 процедуре обновления генератора.

Значение функции сгенерированного распределения в точке  $\mathbf{x}$  есть  $p_g(\mathbf{x}) = \frac{1}{m} \sum_{i=1}^m \mathcal{I}(G(z_j) = \mathbf{x})$  , где  $\mathcal{I}(\cdot)$  – индикаторная функция. В алгоритме будет использована гладкая аппроксимация индикаторной функции

$$k_\sigma(\mathbf{x}) = \exp(-\frac{\|\mathbf{x}\|_2^2}{\sigma^2}), \quad (3)$$

где  $\sigma$  – положительный гиперпараметр. При  $\sigma \rightarrow 0$ ,  $k_\sigma(G(z_j) - \mathbf{x}) \rightarrow \mathcal{I}(G(z_j) = \mathbf{x})$ . Перед обновлением параметра генератора производится обновление генерируемого распределения (6). Обновление двойственной переменной, в данном случае  $p_g(x_i)$ , в прямо-двойственном алгоритме производится по правилу

$$\tilde{p}_g(\mathbf{x}_i) = p_g(\mathbf{x}_i) - \alpha \frac{\partial L(\mathbf{D}, \mathbf{p}_g)}{\partial p_g(\mathbf{x}_i)} = p_g(\mathbf{x}_i) - \alpha f_1(D(\mathbf{x}_i))$$

59 Добавление второго слагаемого в функцию потерь (7) заставляет GAN  
 60 генерировать образцы из распределения все более и более близкого к

---

**Algorithm 1:** Training GAN via Primal-Dual Subgradient Methods

---

**Initialization:** : Choose the objective function  $f_0(\cdot)$  and constraint function  $f_1(\cdot)$  according to the GAN realization. For the original GAN based on Jensen-Shannon divergence,  $f_0(D) = \log(D)$  and  $f_1(D) = \log(2(1 - D))$ .

**while** the stopping criterion is not met **do**

    Sample minibatch  $m_1$  data samples  $x_1, \dots, x_{m_1}$

    Sample minibatch  $m_2$  noise samples  $z_1, \dots, z_{m_2}$ ;

**for**  $k = 1, \dots, k_0$  **do**

        Update the discriminator parameters with gradient ascent:

$$\nabla_{\theta_d} \left[ \frac{1}{m_1} \sum_{i=1}^{m_1} f_0(D(\mathbf{x}_i)) + \frac{1}{m_2} \sum_{j=1}^{m_2} f_1(D(G(\mathbf{z}_j))) \right]. \quad (4)$$

**end**

    Update the target generated distribution as:

$$\tilde{p}_g(\mathbf{x}_i) = p_g(\mathbf{x}_i) - \alpha f_1(D(\mathbf{x}_i)), i = 1, \dots, m_1, \quad (5)$$

    where  $\alpha$  is some step size and

$$p_g(\mathbf{x}_i) = \frac{1}{m_2} \sum_{j=1}^{m_2} k_\sigma(G(\mathbf{z}_j) - \mathbf{x}_i) \quad (6)$$

    With  $\tilde{p}_g(\mathbf{x}_i)$  fixed, update the generator parameters with gradient descent:

$$\nabla_{\theta_g} \left[ \frac{1}{m_2} \sum_{j=1}^{m_2} f_1(D(G(\mathbf{z}_j))) + \frac{1}{m_1} \sum_{i=1}^{m_1} \left( \tilde{p}_g(\mathbf{x}_i) - \frac{1}{m_2} \sum_{j=1}^{m_2} k_\sigma(G(\mathbf{z}_j) - \mathbf{x}_i) \right)^2 \right]. \quad (7)$$

**end**

---

## 63 4. Эксперименты

### 64 4.1. Модельный эксперимент

65 В данном разделе приведён эксперимент, аналогичный описанному в п.  
 66 7.3 приложения к [6]. В оригинальном эксперименте истинное распреде-  
 67 ление вырожденное:  $p_d(x) = 1$  ( $x = 1$ ) (с вероятностью  $p = 1$  элемент вы-  
 68 борки  $x$  принимает значение 1). Мы модифицировали эксперимент, взяв  
 69 истинные данные из распределения  $x \sim \mathcal{N}(1, 10^{-3})$ . Архитектура GAN  
 70 для этого эксперимента приведена в Таблице 1. Параметры сети в прямо-  
 71 двойственном методе обновляются с помощью ADAM ([6]). Результаты  
 72 обучения GAN для стандартного и предложенного метода представлены  
 на рис. 1. Код доступен в репозитории по ссылке.




Рис. 1: Результаты обучения GAN в модельном эксперименте: а) для стандартного метода тренировки, б) для прямо-двойственного субградиентного метода.

	Генератор	Дискриминатор
Вход	$\mathbb{R}$	$\mathbb{R}$
Скрытый слой	32 нейрона + ReLU	32 нейрона + ReLU
Выход	$\mathbb{R}$	$\sigma(\mathbb{R})$

Таблица 1: Архитектура GAN в модельном эксперименте

73

### 74 4.2. Эксперимент с MNIST

75 В данном разделе приведены результаты тестирования предложенного  
 76 метода на датасете MNIST. Размер обучающей выборки – 60 000 сэмплов.

77 На Рис. 2 представлены изображения, которые генерирует GAN в резуль-  
78 тате обучения. В результате обучения обоими методами GAN генерирует  
79 сопоставимые по качеству изображения. Архитектура нейросетей также  
80 представлена в Таблице 2.

	Дискриминатор	Генератор
Вход	Картинка ( $28 \times 28 \times 1$ )	Массив из $\mathbb{R}^4$
Слой 1	Conv2D ( $14 \times 14 \times 128$ )	Dense 3136
Слой 2	Leaky ReLU	Dropout 3136
Слой 3	Dropout	Reshape ( $7 \times 7 \times 64$ )
Слой 4	MaxPooling 2D ( $7 \times 7 \times 128$ )	UpSampling2D ( $14 \times 14 \times 64$ )
Слой 5	Conv2D ( $7 \times 7 \times 128$ )	Conv2D ( $14 \times 14 \times 64$ )
Слой 6	Leaky ReLU	Dropout ( $14 \times 14 \times 64$ )
Слой 7	Dropout	Conv2D ( $14 \times 14 \times 32$ )
Слой 8	Flatten 6272	Dropout ( $14 \times 14 \times 32$ )
Слой 9	-	UpSampling2D ( $28 \times 28 \times 32$ )
Выход	Dense ( $\{0, 1\}$ )	Conv2D ( $28 \times 28 \times 1$ )

Таблица 2: Архитектура GAN в эксперименте MNIST

## 81 5. Заключение

82 В данной работе проведено тестирование предложенного в статье [6]  
83 прямо-двойственного метода на задаче, в которой истинные данные рас-  
84 пределены как  $x \sim \mathcal{N}(1, 10^{-3})$ . Как видно из Рис. 1, в результате обуче-  
85 ния с помощью прямо-двойственного субградиентного метода GAN начи-  
86 нает генерировать данные, распределение которых значительно отлича-  
87 ется от истинного. Мы пока не знаем, как интерпретировать полученный  
88 результат. По какой-то причине субградиентный прямо-двойственный  
89 метод в случае гауссовского распределения ( $x \sim \mathcal{N}(1, 10^{-3})$ ) оказываает-  
90 ся менее предпочтительным с точки зрения качества в сравнении с гра-  
91 диентным спуском. Нашей возможной дальнейшей задачей может быть  
92 изучение границ применимости предложенного в статье [6] метода. Так-  
93 же интересен вопрос выбора оптимизатора, который мы в данной работе  
94 не затрагиваем. Важным направлением дальнейшей работы является  
95 попытка дать интерпретацию Алгоритму 1 (см. раздел 3).

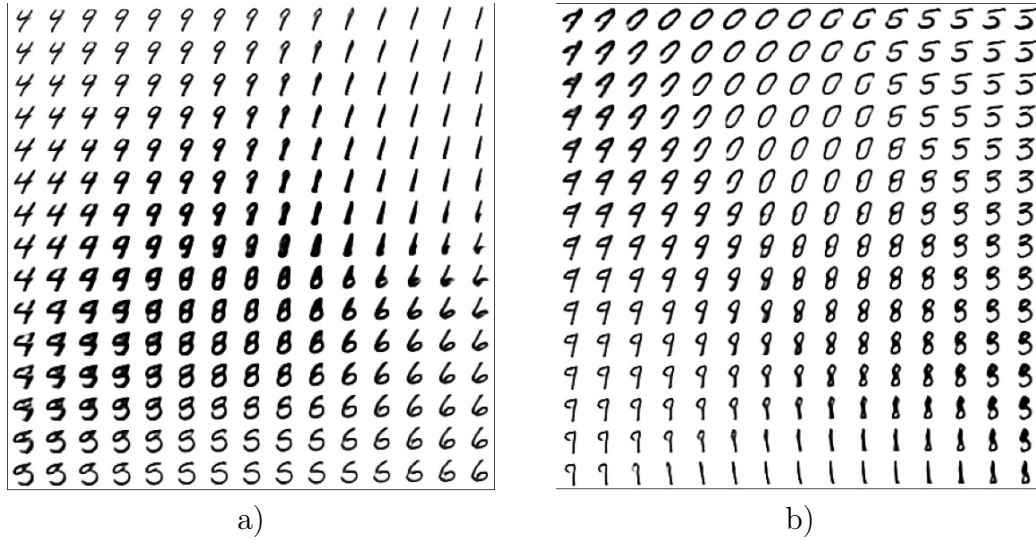


Рис. 2: Результаты обучения GAN в случае тренировки а) стандартным методом, б) прямо-двойственным субградиентным методом.

## Список литературы

- [1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, Generative adversarial nets, in: Advances in neural information processing systems, 2014, pp. 2672–2680.
- [2] S. Lu, R. Singh, X. Chen, Y. Chen, M. Hong, Understand the dynamics of gans via primal-dual optimization (2018).
- [3] J. Engel, K. K. Agrawal, S. Chen, I. , Gulrajani, C. Donahue, A. Roberts, Adversarial neural audio synthesis (2019).
- [4] M. Arjovsky, S. Chintala, L. Bottou, Wasserstein gan (2017).
- [5] L. Metz, B. Poole, D. Pfau, J. Sohl-Dickstein, Unrolled generative adversarial network (2017).
- [6] X. Chen, J. Wang, H. Ge, Training generative adversarial networks via primal-dual subgradient methods: A lagrangian perspective on gan, arXiv preprint arXiv:1802.01765 (2018).